Q-learning: Cliff Walking

En esta práctica se implementó el algoritmo Q-learning para resolver el entorno Cliff Walking, una cuadrícula de 4×12 donde el agente debe llegar desde la posición inicial (3,0) hasta la meta (3,11), evitando un acantilado. Cada movimiento normal tiene una recompensa de -1, mientras que caer en el acantilado genera una penalización de -100 y devuelve al agente al inicio sin terminar el episodio.

Para el entrenamiento se utilizaron 500 episodios, una tasa de aprendizaje de 0.5, un factor de descuento de 1.0, un epsilon de 0.1 y la semilla 42. El agente utilizó una tabla Q y una estrategia epsilon-greedy para aprender qué acciones le permiten alcanzar la meta.

Al finalizar, la política aprendida encontró una ruta de 13 pasos: primero se mueve al norte, después avanza once veces al este y finalmente al sur. Obtuvo un retorno de -13, correspondiente a la ruta óptima.

Se generaron un archivo CSV con las recompensas de cada episodio y una gráfica con la media móvil de 10 episodios. Con esta práctica se comprobó cómo Q-learning aprende mediante recompensas y penalizaciones para encontrar una ruta que permita alcanzar el objetivo evitando las zonas peligrosas.